ArnoBot Voice — plan

Dit document legt de besluiten vast voor de nieuwe abonnementslaag "ArnoBot Voice" en de bijbehorende technische aanpak. Besluiten hieronder staan vast. Zie Status voor waar het traject nu staat, en Beantwoorde ontwerpvragen onderaan voor de ontwerpbeslissingen genomen na de eerste audit.

Let op (2026-08-10): de bedragen/namen hieronder (bijv. "basis/premium/team", €97/mnd) zijn een momentopname van 2026-07-19/20. De abonnementsstructuur is sindsdien verder herzien naar Basic/Pro/Team met nieuwe tarieven, zie `docs/PRICING_DECISIONS.md` voor de actuele, geldende bedragen. Dit document blijft staan als historisch besluitenlog voor de voice-functionaliteit zelf, niet als actuele prijsbron.

Concept — grotendeels besloten en gebouwd (2026-07-20), zie Status hieronder voor details

Arno's ruwe schets van een uitgebreider abonnementsmodel, hier vastgelegd zodat het niet verloren gaat. De twee resterende open onderdelen (agenda-boeking, basis/premium/team-structuur) zijn op 2026-07-20 besloten en gebouwd, zie de Status-sectie verderop voor de volledige uitwerking.

- 30 dagen gratis trial (bestaand).
- Tijdens trial: beperkte voice-toegang (~100 gesproken antwoorden, tekst onbeperkt). Bij plafond: upgrademelding naar een betaald abonnement. **Dit deel is al gebouwd** (zie hieronder, `hasVoiceAccess()` / `TRIAL_VOICE_CHAR_CAP`), sluit goed aan.
- Eén in te plannen gesprek met Arno zelf, **voor iedereen** (verduidelijkt): trial-gebruikers moeten het binnen hun 30 dagen inplannen, betaalde gebruikers kunnen het gebruiken wanneer ze willen, geen tijdslimiet. Nog niet uitgewerkt: planningsmechanisme (koppeling met Arno's agenda), en hoe bijgehouden wordt of iemand 'm al gebruikt heeft. Substantiële nieuwe feature, apart te plannen.
- Na de trial: alleen betalende gebruikers kunnen de app nog gebruiken. Drie voorgestelde abonnementen:
  - **Basis** (naam volgt nog): **verduidelijkt** — de huidige regels blijven gelden (mic-knop voor spraak-naar-tekst-invoer, tekst als output), geen voice-naar-voice-gesprek. Het volledige gesproken heen-en-weer-gesprek (ElevenLabs) is exclusief voor premium.
  - **Premium**: voice-naar-voice, ~200 berichten/maand, daarna **bijkoopbundels** (verduidelijkt, bv. 100 gesprekken voor €10, exacte prijs/aantal nog uit te zoeken)

– geen upgrade naar een hogere laag, gewoon losse bundels bijkopen, zoals al genoemd in Besluit 4 hieronder.
    - **Team: besloten en gebouwd (2026-07-20)** – all-in: per seat/meerdere gebruikers, elke gebruiker in het team krijgt premium-niveau (incl. voice). Prijs op aanvraag, geen self-serve prijs. Blijft bewust losstaand van de bestaande, andere teamfunctie (`arnobot_teams` / `arnobot_team_members`, zelf-service tot 25 leden, collaboration-feature zonder billing-koppeling) – geen technische koppeling tussen de twee.
- In de app: antwoorden altijd kort/normaal. Document-upload en uitgebreide antwoorden blijven exclusief voor de webapp.
- **Besloten en gebouwd (2026-07-20):** basis/premium/team vervangt de oude `tier` (`'basis'|'pro'`)+`voice_enabled`-combinatie volledig via één nieuwe kolom `plan` (`'basis'|'premium'|'team'`) op `approved_users`. Premium = de oude combinatie pro+voice_enabled=true, één product op één prijs (€97/mnd). Zie Status hieronder voor de volledige migratie en de lijst gewijzigde bestanden.
- **Besluit, meteen uitgevoerd (2026-07-19):** de bestaande per-bericht OpenAI-TTS-knop (▶, `tts-1-hd` / `onyx`) wordt uit `SparClient.tsx` verwijderd. Reden van Arno: kwaliteit is "schandalig slecht", en nu het volledige gesproken gesprek toch exclusief voor premium wordt, heeft een matige gratis versie ernaast geen functie meer. De onderliggende `/api/tts`-route blijft ongebruikt maar aanwezig, niet apart opgeruimd. De ElevenLabs-voice-mode-toggle en de herafspeelknop op voice-antwoorden blijven volledig intact, dit raakt alleen het oude OpenAI-pad.
- **Gesprek-met-Arno-boeking: besloten en gebouwd (2026-07-20).** Zie Status hieronder voor de volledige uitwerking (Calendly, redirect-pagina, webhook, dag21-reminder).

Sessie-start-synthese: agenda-boeking + abonnementsherstructurering

Dit is bedoeld om als openingsbericht te plakken in een nieuwe sessie. Kopieer alles hieronder tot aan de volgende `---`.

We gaan twee samenhangende, nog niet geïmplementeerde onderdelen van ArnoBot Voice uitwerken. Lees eerst `docs/VOICE_PLAN.md` (het hele "Concept"-blok bovenaan, en de Status hieronder) en `docs/MOBILE_PLAN.md`, vat in twee zinnen samen waar we staan, en wacht op akkoord voordat je verdergaat, zoals gebruikelijk bij dit project.

Onderdeel 1 — één in te plannen gesprek met Arno, per gebruiker Besloten: geldt voor iedereen. Trial-gebruikers moeten het binnen hun 30-dagen-trial inplannen, betaalde gebruikers kunnen het gebruiken wanneer ze willen, geen tijdslimiet. Nog open, eerst uitzoeken/beslissen:

- Bouw je dit met een bestaande scheduling-tool (bv. Calendly/SavvyCal/Cal.com, embed of link) of met een eigen Google Calendar-integratie? Een bestaande tool is vermoedelijk veel sneller en betrouwbaarder dan zelf een boekingsflow plus agenda-koppeling bouwen, dat zou ik als eerste vraag voorleggen aan Arno, met een duidelijke aanbeveling.
- Let op: deze Claude Code-sessie heeft mogelijk Google Calendar-MCP-tools beschikbaar (`mcp__claude_ai_Google_Calendar__*`), maar dat is iets anders dan een integratie die de ArnoBot-productie-app zelf kan gebruiken. Niet verwarren: die MCP-tools zijn voor Claude Code zelf tijdens een sessie, niet voor eindgebruikers van de app.
- Hoe wordt bijgehouden of een gebruiker zijn ene gesprek al gebruikt heeft (nieuwe kolom op `approved_users`, of een aparte tabel)?
- Waar in de UI komt dit te staan (webapp en/of app)?

Onderdeel 2 — drie abonnementen: basis, premium, team Besloten (zie het Concept-blok in VOICE_PLAN.md voor de volledige context):

- **Basis**: geen voice-naar-voice-gesprek, wel de bestaande mic-knop (spraak-naar-tekst-invoer), tekst als output.
- **Premium**: volledig gesproken heen-en-weer-gesprek (ElevenLabs), ~200 berichten/maand, daarna bijkoopbundels (richting: 100 gesprekken voor €10, exacte prijs/aantal nog te bepalen).
- **Team**: nog geen details, moet nog uitgedacht worden. Nog open:
- Hoe verhoudt basis/premium/team zich tot de bestaande `tier`-kolom (`'basis' | 'pro'`) en de losse `voice_enabled`-boolean op `approved_users`? Vervangt dit die kolommen, of komt het ernaast?
- Migratie van bestaande gebruikers naar de nieuwe indeling.
- Prijzen voor premium en team.
- Hoe dit samenhangt met fase 3 (pricingpagina) uit VOICE_PLAN.md, die al blokkeert op de nog te kiezen betaalprovider.

Begin met vragen stellen over de onduidelijke punten hierboven, dan pas een plan.

Status

Laatst bijgewerkt: 2026-11-01

Karaoke-highlight + meescrollen tijdens voice-out (gebouwd 2026-09-29). Aanleiding: op mobiel las je het antwoord niet meer vanaf het begin, de tekst gaf geen houvast bij het gesprokene. `/api/tts-voice` gebruikt ElevenLabs' `/with-timestamps`-functionaliteit (`fetchElevenLabsSpeechWithAlignment` in `lib/voice.ts`) i.p.v. de ruwe audio-stream: complete audio (base64) plus karakter-niveau alignment. Client (`SparClient.tsx`): `buildSpeakTokens` / `findActiveSpeakToken` zetten de alignment om naar woord-tokens, `startSpokenPlayback()` (gedeeld door de voice-mode auto-play én de handmatige ▶-herafspeelknop) bouwt een blob-URL en highlight/scrollt het huidige woord via `ontimeupdate`. Los daarvan is ook het geforceerde meescrollen naar de onderkant tijdens het gewone (niet-voice) streamende antwoord verwijderd: dat volgde de groeiende tekst nu alleen nog als je al onderaan de pagina stond, in plaats van bij elke chunk. **Latency-fix (2026-09-29, zelfde dag):** eerste implementatie gebruikte bewust de NIET-streamende `/with-timestamps`-endpoint (chunk-relatieve vs. cumulatieve timing van de streamende variant was niet gedocumenteerd te verifiëren). Arno rapporteerde daarna trage voice-out (tot 10s). Gemeten: niet-streamend 2,3s vs streamend 0,65s voor een gemiddeld voice-antwoord, ElevenLabs levert bij de streamende variant audio zodra 'm gegenereerd is i.p.v. te wachten tot de hele clip klaar is. Karakter-tijden in de streamende NDJSON-chunks bleken bij directe meting cumulatief over de hele stream (niet chunk-relatief), dus alsnog overgeschakeld naar `/stream/with-timestamps`, server-side samengevoegd tot dezelfde JSON-vorm. Client ongewijzigd, wacht nog wel op complete audio vóór afspelen (bewust geen MediaSource, onbetrouwbaar op mobiele Safari). **Voice-in stap 1: model-swap + SSE-streaming (gebouwd 2026-09-29).** Capability-sweep voorgelegd (whisper-1/gpt-4o-transcribe/gpt-4o-mini-transcribe qua ruwe latency vergelijkbaar op een kort fragment, geen winst door alleen het model te wisselen; SSE-streaming verbetert vooral de beleving bij langere opnames; volledige realtime via WebRTC (`gpt-live-transcribe`) is de enige aanpak die de wachttijd na loslaten van de mic-knop echt wegneemt, maar is een losstaande architectuurbouw). Arno akkoord: optie A (model-swap + streaming) nu, optie B (volledige realtime-herbouw) **overmorgen, 2026-10-01.** `/api/transcribe/route.ts`: `whisper-1` → `gpt-4o-transcribe`, `stream=true`, proxyt de SSE-bytes door. `SparClient.tsx` (`startRecording`'s `recorder.onstop`): parset de SSE zelf, vult het invoerveld progressief per `transcript.text.delta`-event i.p.v. te wachten op één blokkerende JSON-respons. Lost tegelijk de whisper-1-deprecatie op (hard shutdown 26 februari 2027). **Voice-in stap 2: volledige realtime-herbouw met WebRTC, gepland 2026-10-01, nog NIET gebouwd.** `gpt-live-transcribe`, transcribeert al terwijl je spreekt (delta-events tijdens het opnemen), dus het "wachten na loslaten van de knop" verdwijnt vrijwel volledig. Architectuur: WebRTC-verbinding vanuit de browser, ephemeral realtime-sessietokens die de server per opname

aanmaakt (geen API-key naar de client), client-side VAD niet nodig (onze mic-knop is al push-to-talk: indrukken=start, loslaten=stop, dat is al de eind-van-spraak-detectie). Kosten $0,017/min vs. $0,006/min bij het huidige model, verwaarloosbaar op ArnoBot's volumes. Dit werk is ook de voorwaarde voor `docs/MOBILE_PLAN.md` fase 4 (native app store), zie geheugen `project_mobiel_voice_strategie`. **Gebouwd 2026-11-01: live transcriptie (stap 2) en modelwissel.** OpenAI bevestigde op de officiële deprecations-pagina dat `gpt-4o-transcribe`, `whisper-1` en `gpt-4o-mini-transcribe` per 2027-02-26 uit de API gaan. Gekozen: (1) de gewone transcriptie (`/api/transcribe`, ook de terugval) is gewisseld naar `gpt-transcribe` (zelfde SSE-events, sneller); (2) live transcriptie met `gpt-live-transcribe`. Gemeten op 20 Nederlandse verkoopzinnen: alle drie de modellen 2,4 tot 3,1% woordfouten, dus de winst is snelheid en gevoel (tekst terwijl je praat, eerste tekst na ongeveer 1,7 s, definitief 0,7 s na stoppen). Gekozen transport: WebSocket vanuit de browser met lokaal opgevangen audio (AudioWorklet, buffer tot de verbinding open is). Verworpen: WebRTC, want de eerste 1 tot 2 seconden gesproken tekst gingen verloren tijdens het verbinden (gemeten: "Ik heb vanochtend gebeld met Jansen" ontbrak). Verworpen: alleen `gpt-transcribe` (A), want live typen was de wens van 2026-09-29. Terugval: bij elke fout of een niet-beschikbare sessiecode loopt alles via de opname na het stoppen. Achter `LIVE_TRANSCRIBE=aan` (Vercel): zonder die variabele alleen voor de eigenaar en interne testaccounts. Kosten: $0,017 per minuut (live) tegenover $0,0045 (gewoon). Nog open: live testen door Arno op een echte telefoon (iPhone Safari en Android Chrome), daarna `LIVE_TRANSCRIBE=aan` zetten; Abacus kent de dicteerkosten nog niet per minuut; de privacytekst noemt nog niet dat het geluid bij live rechtstreeks van de browser naar OpenAI gaat (voorstel eerst aan Arno tonen).

Stand 2026-11-01 (maandcheck, voor de bouw hierboven): de geplande datum 2026-10-01 voor de WebRTC-herbouw (stap 2) is verstreken zonder dat die is gebouwd. Sindsdien zijn alleen kleinere voice-in-fixes gedaan (opname met echt formaat naar transcriptie, melding alleen als er echt niets is omgezet, klik-klik microfoon die stopt na stilte). **Let op:** een secundaire bron (dev.to, niet officieel bevestigd) meldt dat `gpt-4o-transcribe` op 2027-02-26 uit de API gaat, met `gpt-transcribe` of `gpt-live-transcribe` als vervanger. Eerst verifiëren op de officiële OpenAI-deprecationspagina (of `shutdown_date` via GET /v1/models). Bevestigt dit zich, dan wordt de WebRTC-herbouw (`gpt-live-transcribe`) de migratieroute en krijgt die een harde deadline. **Bijgewerkt 2026-11-04:** `LIVE_TRANSCRIBE` stond in Vercel al op `aan` (Arno), live transcriptie is dus voor alle gebruikers open. **Besluit Arno 2026-11-04: de privacytekst nu niet aanpassen.** Let op: `/privacy` en het beveiligings-PDF noemen nog niet dat het geluid bij live dicteren rechtstreeks van de browser naar OpenAI gaat (de OpenAI-regel zegt alleen "Spraakherkenning voor voice-invoer"). Voorgestelde tekst staat in de sessie van 2026-11-04: "Bij live dicteren gaat het geluid vanuit je browser rechtstreeks naar OpenAI, niet via onze server, en alleen terwijl de microfoon aan staat (geen training op jouw data)." Nog open: live testen op een echte iPhone (Safari) en Android (Chrome), en live testen van de voice-out-fix.

Vorige status-update (2026-08-13):

Traject afgerond en volledig live (2026-07-20): plan-kolom + gesprek-met-Arno-boeking + upgrade-flows. Voor de volledige, actuele abonnementsstructuur zie `docs/ABONNEMENTEN.md` (dat document wordt voortaan bijgehouden bij elke wijziging aan de plan-structuur, dit VOICE_PLAN-statusblok blijft het bouw-logboek van deze specifieke sessie).

Voice-out tijdelijk uitgezet voor iedereen behalve Arno zelf (besloten en gebouwd 2026-08-13). Aanleiding: Arno logde in via zijn eigen LinkedIn-account (`linkedin@royaldutchsales.com`) en zag daar voice-out functioneren, wat hem deed vragen of dat ook bij andere gebruikers zo was. Bleek zo te zijn, en bewust zo gebouwd (`proxy.ts` zet `plan: 'premium'` voor elke nieuwe trial-aanmelding, en `hasVoiceAccess()` gaf daardoor iedereen ongelimiteerde paid-toegang, ook trial-gebruikers, zie het "Openstaand actiepunt" hierboven over de nooit bereikte `TRIAL_VOICE_CHAR_CAP`). Arno wil voice-out nu eerst uitsluitend zelf verder testen, tot de commerciële livegang (nog niet gepland, zie geheugen `project-launch-date-postponed`, vermoedelijk sept/okt 2026). **Bewust besluit, expliciet nagevraagd:** dit geldt ook voor de 6 bestaande, echt betalende gebruikers die voice al gebruikten (`thijs@tenshare.nl`, `rtesfahuny@hotmail.com`, `stefanie_coster@hotmail.com`, `dyannethornleeson@gmail.com`, `charles.deklerk@xs4all.nl`, `erik.van.den.berg@xs4all.nl`, gevonden via `approved_users` met `paid_at IS NOT NULL`), niet alleen voor nieuwe/trial-aanmeldingen. Ter vergelijking eerst voorgelegd of dit de bedoeling was (zij verliezen een functie waar ze al voor betalen, zonder aankondiging), Arno bevestigde expliciet: ja, iedereen behalve zijn eigen twee accounts. **Implementatie:** `lib/voice.ts` (`VOICE_LAUNCH_RESTRICTED`, `VOICE_ALLOWED_USER_IDS`, `isVoiceLaunchAllowed()`) is de enige plek met de allowlist, met een duidelijke verwijderinstructie in de code zelf voor zodra Voice commercieel live gaat. Toegepast op twee niveaus: `hasVoiceAccess()` (server-side enforcement, dekt zowel `/api/chat-voice` als `/api/tts-voice`, want beide roepen die functie al aan) én `app/bot/page.tsx` (`voiceEnabled`, verbergt de voice-toggle in de UI voor iedereen buiten de allowlist, i.p.v. een zichtbare knop die vervolgens een foutmelding geeft). De admin-only testroute (`/bot/admin/voice-test`) is bewust ongemoeid gelaten, die gebruikt `hasVoiceAccess()` niet en blijft dus altijd werken voor Arno, ongeacht deze restrictie. **Allowlist:** `MANUAL_TEST_USER_ID` (test@arno.bot, uit `lib/internalTestAccounts.ts`) en het userId van `linkedin@royaldutchsales.com` (Arno's echte LinkedIn-account, elders in de codebase bekend als `BOUWER_EMAIL`, hier hardcoded als userId opgezocht via Supabase omdat de betrokken routes geen e-mailadres ophalen). **Niet aangepast:** marketingcopy op `/prijzen` / `docs/ABONNEMENTEN.md` die voice als Pro/Team-feature beschrijft, blijft ongewijzigd staan (correct voor na de livegang, alleen de daadwerkelijke toegang is nu tijdelijk beperkt). Geen nieuwe kolom of feature-flag in Supabase, puur een hardcoded allowlist in code, bewust tijdelijk en eenvoudig terug te draaien. **Eerstvolgende stap:** geen. Bij de daadwerkelijke commerciële livegang: `VOICE_LAUNCH_RESTRICTED` op `false` zetten (of het hele blok verwijderen) in `lib/voice.ts`.

Abonnementsherstructurering: `tier` (`'basis'|'pro'`) + `voice_enabled` volledig vervangen door één kolom `plan` (`'basis'|'premium'|'team'`) op `approved_users`. Alle codeplekken omgezet, admin-

toggle vervangen (`PlanToggle.tsx`, 3-way, `/api/admin/plan`). **Migratie 2 uitgevoerd en bevestigd:** kolommen `tier` en `voice_enabled` zijn gedropt, de omzetting is daarmee volledig afgerond, geen legacy-kolommen meer.

Kritieke bug gevonden en gefixt, zelfde dag: de nieuwe `plan`-kolom kreeg aanvankelijk `DEFAULT 'basis'`, en `proxy.ts` zette `plan` nooit expliciet bij provisioning. Nieuwe trial-aanmeldingen kregen daardoor stilzwijgend een beperkte ervaring (geen coaching, geen voice, 25 berichten/dag) in plaats van de bedoelde volledige functionaliteit tijdens de 30-dagen-trial (zoals vóór de migratie ook al zo werkte, toen stond `tier` default op `'pro'`). Ontdekt en gefixt vóórdat nieuwe gebruikers hierdoor geraakt zijn: `plan: 'premium'` nu expliciet in `proxy.ts`, kolom-default in Supabase gelijkgetrokken naar `'premium'`. Zie `docs/ABONNEMENTEN.md` voor de volledige toelichting.

Gesprek-met-Arno-boeking: Calendly (event `arnobot/ab`) als scheduling-tool. Nieuwe kolom `arno_call_booked_at` op `approved_users`. `app/bot/gesprek/page.tsx`: eerst een Calendly-embed geprobeerd, teruggedraaid naar een externe link (nieuw tabblad) omdat kleuraanpassing aan het donkere thema een betaald Calendly-plan vereist en de embed een storende interne scroll gaf. Robuuste matching via `utm_content=<Clerk-userId>` in de link (komt terug in de webhook-payload `payload.tracking.utm_content`, onafhankelijk van wat iemand zelf in het Calendly-formulier invult), met e-mailmatching als fallback voor boekingen buiten de app om. Webhook `app/api/webhooks/calendly/route.ts` (HMAC-SHA256-signatuurverificatie + 5 min replay-venster). Reminder-e-mail `dag21_gesprek` toegevoegd aan `lib/email-templates.ts` + trigger in de bestaande `app/api/cron/trial-emails/route.ts`-loop.

Upgrade-flows (nieuw t.o.v. het oorspronkelijke plan, ontstaan tijdens de sessie): `/bot/upgrade` (basis→premium en premium→team, mailto + klik-tracking, geen self-serve betaling). `/upgrade` (ArnoLive/ArnoPrime, Arno's eigen consulting-aanbod, los van ArnoBot-abonnementen) verplaatst naar `/arnolive` om de naamsclash op te lossen. Boekingskaart op de accountpagina weer verwijderd op Arno's verzoek: het gesprek loopt alleen via de dag21-mail en de coaching-pagina, niet via een permanente accountpagina-kaart.

Build (`npm run build`), typecheck en lint zijn na elke stap gecontroleerd. Regressietest is door Arno zelf op productie gedaan, inclusief screenshots per stap; alle gevonden problemen (verouderde "Pro"-copy, teller die weg moest, knopbreedtes, het embed-scrollprobleem, de trial-plan-bug) zijn binnen deze sessie gevonden en gefixt.

Eerstvolgende stap: geen actief bouwwerk. Open, niet-blokkerend punt: een echte proefboeking om de webhook-matching end-to-end te bevestigen is bewust overgeslagen (Arno vertrouwt de matching-logica), kan alsnog als losse verificatie.

Laatst bijgewerkt (vorige sessie): 2026-07-19 **Waar we staan:** Scope van de eerste bouwstap bijgesteld tijdens deze sessie (zie hieronder): niet meteen een publieke voice-toggle in

`SparClient.tsx`, maar eerst alleen de serverkant plus een volledig geïsoleerde admin-only testpagina op `/bot/admin/voice-test` (`app/api/admin/voice-test/chat/route.ts`, `app/api/admin/voice-test/tts/route.ts`), gebouwd en gepusht. Supabase-tabel `arnobot_elevenlabs_usage` aangemaakt en bevestigd. ElevenLabs-account aangemaakt (Starter-plan, API-key beperkt tot alleen Text to Speech). Nul wijzigingen aan `SparClient.tsx` / `/api/chat` / `/api/tts` / `/api/transcribe`.

Gekozen (2026-07-19): voor deze testfase Instant Voice Cloning gebruiken (een korte, snelle opname van Arno zelf, inbegrepen in het Starter-plan) in plaats van een generieke Nederlandse bibliotheekstem. Reden: het doel van deze test is niet alleen "klinkt ElevenLabs goed", maar vooral "klinkt ArnoBot als Arno", en dat kun je met een bibliotheekstem niet beoordelen. **Verworpen alternatief:** een Nederlandse bibliotheekstem (het oorspronkelijke voorstel in Besluit 2 hieronder) — sneller te kiezen maar test niet de eigenlijke productvraag. **Kanttekening:** Instant Voice Cloning is een snellere, lagere-kwaliteit variant dan de Professional Voice Clone die het einddoel blijft (zie Besluit 2). Een houterige instant clone is geen voorspelling van hoe de uiteindelijke Professional clone zal klinken, dat oordeel wordt uitgesteld tot dat traject. Deze testfase beoordeelt vooral latency, stijl en of het concept "een versie van mijn stem" sowieso werkt.

Getest en goedgekeurd door Arno (2026-07-19): live test op `/bot/admin/voice-test` met de instant-clone-stem geslaagd. Latency, antwoordstijl en stemkwaliteit akkoord.

Besluit publieke uitrol (herbevestigd 2026-07-19): ook op de webapp, niet mobiel-only, maar uitsluitend voor Voice-abonnees (premium, €97/mnd) via de losse `voice_enabled`-kolom, zoals al vastgelegd in ontwerpvraag 2. Zie ook het overleg eerder deze sessie waarin dit expliciet is herbevestigd na een korte omweg via "misschien mobiel-only".

Gebouwd en live getest door Arno (2026-07-19): de echte, premium-gated integratie staat in `SparClient.tsx` (`voice_enabled`-kolom op `approved_users`, nieuwe routes `app/api/chat-voice/route.ts` + `app/api/tts-voice/route.ts`, gedeelde logica in `lib/voice.ts`, hergebruikt door de admin-testroutes). **Architecturale correctie t.o.v. het eerdere `VoiceMode.tsx`-idee:** géén apart component gebruikt, de logica haakt direct in `ask()` / `speak()` in minimale, geïsoleerde branches, dat bleek een kleiner en veiliger diff-oppervlak dan een apart component optillen. Volledige voice-round-trip (toggle aan, vraag stellen, gesproken antwoord terug) live getest door Arno op productie: werkt. ElevenLabs toegevoegd aan privacypagina en beveiligingsdocument (versie 1.2), "Improve the models for everyone" uitgezet in het ElevenLabs-dashboard.

Regressiecheck bevestigd door Arno (2026-07-19): normale chat, de bestaande ▶-knop met OpenAI-stem en snelheidsmenu, sparren-modus, bestand bijvoegen, en de bestaande mic/STT-knop, allemaal gecheckt zonder voice-mode aan, geen van alle geraakt. Deze bouwstap geldt hiermee als afgerond.

Besluit trial-voice-toegang (2026-07-19, vult fase 2 gedeeltelijk in): elke gebruiker krijgt tijdens de bestaande 30-dagen-gratis-trial (`trial_start`, dezelfde formule als `proxy.ts`) automatisch ook gratis voice-toegang, tot een plafond (`TRIAL_VOICE_CHAR_CAP` in `lib/voice.ts`, ruw geschat op de helft van een nog niet formeel vastgestelde betaalde maandcap). Na de trial, of eerder als het plafond bereikt wordt, alleen nog toegang voor betalende Voice-abonnees (`voice_enabled=true`); wie na de trial een gewoon basis-abonnement neemt, verliest voice-toegang. Bij vroegtijdig plafond-bereik of trial-einde toont de app een upgrademelding met link naar `/prijzen`, geen blokkade zonder uitleg. Gebouwd in `lib/voice.ts` (`hasVoiceAccess()`), toegepast in `chat-voice` / `tts-voice`. **Bewust nog niet gebouwd:** plafond-enforcement voor bestaande betaalde Voice-abonnees zelf (die blijven ongewijzigd oncapped), dat blijft het bredere fase-2-werk.

App-wachtwoord toegevoegd (2026-07-19): nieuwe zelfservice-sectie op `app/bot/account/page.tsx` waarmee een gebruiker (aangemeld via verplichte LinkedIn OAuth) een wachtwoord aan hun account toevoegt, via Clerk's backend-API (`clerkClient.users.updateUser(userId, { password })`, vereist geen bestaand wachtwoord). Reden: de toekomstige mobiele app kan geen LinkedIn-OAuth gebruiken (zie `docs/MOBILE_PLAN.md`), dus wachtwoord-login is het alternatief. Bevestigd: Clerk-dashboard-instelling "Add password to account" stond al aan, geen configuratiewijziging nodig geweest.

Mobiele app losgekoppeld van livegang (2026-07-19, besluit van Arno): ArnoBot kan live gaan op web zonder de mobiele app, die is geen vereiste voor launch. De mobiele-inlog-stukken (`app/sign-in/AppSignIn.tsx`, conditionele branch in de sign-in-pagina, `@capacitor/browser`) zijn wel gebouwd en gecommit, maar bewust niet verder getest/gepolijst nu, de mobiele app zelf staat voorlopig geparkeerd (zie `docs/MOBILE_PLAN.md`).

Eerstvolgende stap: nog geen admin-UI om `voice_enabled` bij andere gebruikers te zetten (alleen handmatige SQL, zoals nu bij Arno zelf); nodig zodra er echte testgebruikers bij komen. Verder: livegang-voorbereiding op web (betaalprovider-keuze blijft blokkerend voor fase 3/pricingpagina, zie fasering hieronder).

Besluiten

1. Abonnementslaag

Nieuwe laag "ArnoBot Voice" voor €97/maand, naast de bestaande Unlimited-laag (€77/maand, zie `app/prijzen/page.tsx`). Voice in en voice uit, eerst op de webapp, later in de (nog te bouwen) mobiele app.

2. TTS-leverancier

ElevenLabs API rechtstreeks (geen reseller), model Flash v2.5, streaming audio. **Achterhaald door het besluit van 2026-07-19 hierboven:** de OpenAI-TTS-knop is uit `SparClient.tsx` verwijderd, niet naast ElevenLabs blijven bestaan zoals hier oorspronkelijk gepland. `app/api/tts/route.ts` zelf is op 2026-08-12 alsnog opgeruimd (was tot dan bewust ongebruikt achtergelaten).

Stem: Professional Voice Clone van Arno. Tot die klaar is, een Nederlandse stem uit de ElevenLabs-bibliotheek, stem-ID als env-variabele (bijvoorbeeld `ELEVENLABS_VOICE_ID`) zodat wisselen naar de clone geen codewijziging vereist.

3. Eigen systeeminstructie voor voice-antwoorden

Voice-antwoorden krijgen een aparte systeeminstructie: gespreksachtige toon, doellengte 400 tot 600 tekens. De bestaande lange tekstantwoorden in de hoofdchat blijven ongewijzigd. Stijlvoorbeeld: de Analyses-samenvattingen.

Dit wordt geïmplementeerd in een nieuwe, losse route (zie ontwerpvraag 1 hieronder), niet als flag binnen de bestaande `app/api/chat/route.ts`. De bestaande streepjes-regel en jij/jou-regel uit CLAUDE.md gelden onverkort voor deze nieuwe systeeminstructie.

4. Verbruiksplafond

Intern meten in tekens/kosten per gebruiker per maand. In de UI tonen als "gesproken antwoorden" (ruim 200/maand, exacte drempel later te bepalen). Bij bereiken van het plafond: vriendelijke melding, daarna naadloos verder in tekst. Nooit blokkeren.

Bijkoopbundels (200 antwoorden voor €10) lopen via de website, niet in-app.

Er bestaat nog geen tabel of kolom voor dit soort meting. Het dichtstbijzijnde patroon is de daglimiet-telling in `arnobot_rds_logs` (rijen tellen via `created_at`-filter, zie `app/api/chat/route.ts:283-291`) maar dat telt berichten, geen tekens/kosten, en niet per maand. Nieuwe tabel of kolommen nodig (zie vraag 3 hieronder).

5. Identificatie per Clerk user-id

Limieten en plafond worden per Clerk user-id geregistreerd, nooit per IP. De bestaande Upstash per-IP rate limiting (`app/api/chat/route.ts:130-147`, sliding window 5/minuut) blijft ongewijzigd als misbruikvangnet, los van het voice-plafond.

6. Geen aankoopflow in de app

App is inloggen en gebruiken. Betalen (nieuwe laag, bijkoopbundels) gebeurt op de website, niet in-app, vanwege Apple/Google-regels voor de toekomstige mobiele app.

7. Afspeellogica voor voice-antwoorden (mobiel-bewezen ontwerpeis, toegevoegd 2026-07-19)

Gekozen: het afspelen van de ElevenLabs-audio start binnen dezelfde tikactie waarmee de gebruiker de vraag verstuurt of het opnemen start. Dat telt als een user gesture, waarna streaming-audio ook op mobiele browsers/webviews mag beginnen. Daarnaast komt er een zichtbare afspeelknop als vangnet voor het geval de gesture-koppeling niet aanslaat.

Verworpen alternatief: automatisch afspelen zodra de tekst binnenkomt, los van een directe gebruikersactie. Werkt niet betrouwbaar op mobiele Safari en Capacitor-webviews door autoplay-restricties (ontdekt tijdens de audit voor `docs/MOBILE_PLAN.md`, zie daar voor de volledige onderbouwing).

Reden dat dit hier staat en niet pas bij fase 4: deze ontwerpeis raakt fase 1 (voice op de webapp), niet alleen de latere mobiele app. Mobiele browsers hebben dezelfde autoplay-restrictie als Capacitor-webviews. Fase 1 moet dus vanaf het begin mobiel-bewezen zijn, niet pas bij fase 4 hersteld worden.

Fasering

Fase 1 — voice-mode in de bestaande webapp achter een feature flag

- [ ] Supabase-migratie: kolom `voice_enabled` (boolean) op `approved_users` — ter bevestiging voorleggen zoals bij elke schema-wijziging
- [ ] Supabase-migratie: nieuwe tabel voor tekenteller per gebruiker per maand — ter bevestiging voorleggen
- [ ] Env-variabelen `ELEVENLABS_API_KEY`, `ELEVENLABS_VOICE_ID`
- [ ] Opname (STT): hergebruik van het bestaande patroon in `SparClient.tsx` (`MediaRecorder`, `getUserMedia`, upload naar `/api/transcribe`) — ongewijzigd, blijft OpenAI Whisper (ontwerpvraag 3)
- [ ] Nieuwe route `app/api/chat-voice/route.ts` met de voice-systeeminstructie (besluit 3, ontwerpvraag 1)
- [ ] Nieuwe route voor ElevenLabs streaming TTS (besluit 2), naast het bestaande `app/api/tts/route.ts`
- [ ] Afspeellogica die binnen de user-gesture start, met zichtbare afspeelknop als vangnet (besluit 7)
- [ ] Voice-mode toggle in `SparClient.tsx`, achter de `voice_enabled`-flag (ontwerpvraag 2). **Bouwrichtlijn (2026-07-19):** nieuwe voice-logica/state in een apart component (bv. `VoiceMode.tsx`) dat `SparClient.tsx` conditioneel mount, niet doorweven in de bestaande 1600+ regels. Kleinste diff-oppervlak in het gedeelde bestand dat alle bot-gebruikers al gebruiken, kleinste kans op regressie voor niet-Voice-gebruikers.

- [ ] Na fase 1: expliciet de bestaande tekst-chat-, TTS- en STT-flow opnieuw testen (regressiecheck) vóórdat fase 1 als afgerond geldt
- [ ] Automatische ElevenLabs-playback voor Voice-abonnees i.p.v. de handmatige OpenAI-knop (ontwerpvraag 4)
- [ ] `package.json`: ElevenLabs toevoegen
- [ ] CLAUDE.md bijwerken: ElevenLabs toevoegen aan de kwartaalcheck-sectie en de modelinventaris-tabel, in dezelfde commit
- [ ] Testen op telefoon in de mobiele browser (gratis generale repetitie voor de latere Capacitor-app, zie `docs/MOBILE_PLAN.md`)

Er bestaat nog geen generiek feature-flag-mechanisme in de codebase (geverifieerd: geen `FEATURE_*`-patroon). Fase 1 introduceert de eerste flag, als losse boolean-kolom op `approved_users`, naast de bestaande `tier`-kolom (`'basis' | 'pro'`).

Fase 2 — plafond-logica, meldingen, tekst-fallback

- [ ] Nog niet in detail uitgewerkt

Fase 3 — pricingpagina met de nieuwe tier, upgradeflow

- [ ] **Blokkerend:** betaalprovider gekozen. Er is geen betaalprovider-integratie in de code (bevestigd in `docs/BUSINESS_HANDOVER.md`); betalingen worden nu handmatig geregistreerd via `/bot/admin/gebruikers` of `POST /api/admin/payment`. De upgradeflow in fase 3 hangt aan deze keuze, dus die moet vóór fase 3 beslist zijn (zie `project_dunning_flow` in memory)
- [ ] Pricingpagina met de €77/€97-opbouw

Fase 4 — Capacitor-app, pas na bewezen fase 1 t/m 3. Volledig uitgewerkt in `docs/MOBILE_PLAN.md`.

Relevante bestaande code (referentie voor bouw)

- **Clerk auth-patroon**: `const { userId } = await auth()` + 401-check, zie `app/api/transcribe/route.ts:2-6`. Voor ingelogde gebruikers wordt `userId` nooit uit de request body vertrouwd (`app/api/chat/route.ts:237-242`).
- **STT**: `app/api/transcribe/route.ts` (Whisper, ruwe fetch, geen SDK). Frontend-opname in `app/bot/SparClient.tsx` (state rond regel 179-180, 251-252; `startRecording` / `stopRecording` rond 270-306; mic-knop UI rond 1652-1666).
- **TTS**: was `app/api/tts/route.ts` (OpenAI `tts-1-hd` / `onyx`), verwijderd op 2026-08-12 (zie besluit 2026-07-19 hierboven). `speak()` in `SparClient.tsx` roept nu uitsluitend `/api/tts-voice` (ElevenLabs) aan, ongeacht plan.
- **CORS**: alleen in `app/api/chat/route.ts:33-52` (`ALLOWED_ORIGINS`: arno.bot, www.arno.bot, arno.blog, www.arno.blog). `transcribe` en `tts` hebben geen CORS-headers, alleen same-

origin gebruik vanuit `arno.bot`.

- **Abonnement**: alles zit plat in de Supabase-tabel `approved_users` (geen aparte subscriptions-tabel, geen Clerk publicMetadata voor abonnementsstatus). Relevante kolommen: `tier` ('basis'/'pro'), `is_active`, `paid_at`, `expires_at`, `trial_start`.
- **Rate limiting**: Upstash-instanties direct in `app/api/chat/route.ts:130-147`, geen gedeelde `lib/ratelimit.ts`. `transcribe` en `tts` hebben momenteel geen eigen rate limiting.
- **Package.json**: geen ElevenLabs-SDK of andere voice-SDK aanwezig. Moet worden toegevoegd in fase 1.

Beantwoorde ontwerpvragen (2026-07-19)

1. **Route-opzet voor de voice-chatflow**: nieuwe losse route (bv. `app/api/chat-voice/route.ts`), niet als flag binnen de bestaande `app/api/chat/route.ts`. Eigen CORS/rate-limit-instellingen, raakt de bestaande hoofdchat niet aan.
2. **Feature flag voor toegang tot ArnoBot Voice**: losse boolean-kolom op `approved_users` (bv. `voice_enabled`), onafhankelijk van de bestaande `tier`-kolom (basis/pro). Voice is een addon, geen vervanging van basis/pro.
3. **STT-leverancier**: blijft OpenAI Whisper via het bestaande `app/api/transcribe/route.ts`. Geen nieuwe leverancier voor spraakherkenning, alleen TTS gaat naar ElevenLabs.
4. **Bestaande per-bericht TTS-knop (OpenAI tts-1-hd/onyx) in `SparClient.tsx`**: voor Voice-abonnees vervangen door automatische ElevenLabs-playback (Flash v2.5, straks Arno's clone) na elk antwoord. ~~Niet-Voice-gebruikers behouden de bestaande handmatige OpenAI-knop ongewijzigd.~~ **Achterhaald, zelfde dag:** zie het besluit bovenaan dit document (2026-07-19), de OpenAI-knop is toen voor iedereen verwijderd, niet alleen vervangen voor Voice-abonnees.

Deze vier antwoorden zijn verwerkt in de fasering hierboven en zijn leidend voor de bouw van fase 1.